

随机事件和概率

一些基本概念

- 样本点：随机试验的每一个可能结果， ω
- 样本空间：所有样本点的集合， Ω
- (随机)事件：样本空间的子集， $A \subset \Omega$

事件的关系

- 互斥事件： $A \cap B = \emptyset$
- 对立事件： $A \cup B = \Omega \wedge A \cap B = \emptyset$

显然 对立事件一定是互斥事件，但互斥事件不一定是对立事件

概率

条件概率定义：

$$P(A|B) = \frac{P(AB)}{P(B)}, \quad P(B) \neq 0$$

这是定义，随时可用。

独立

事件 A 和 B 独立，当且仅当 $P(AB) = P(A)P(B)$ 。

设 A_1, A_2, \dots, A_n 为 n 个事件，若对任意 $k(1 \leq k \leq n)$ (个数)，任意 i_1, i_2, \dots, i_k (组合)，有

$$P(A_{i_1} A_{i_2} \cdots A_{i_k}) = P(A_{i_1}) P(A_{i_2}) \cdots P(A_{i_k})$$

则称 A_1, A_2, \dots, A_n 为相互独立的事件。

将 n 个相互独立的事件中任意几个换成对立事件，这些事件仍然是相互独立的。

注意这里不是两两满足两事件独立就可以了，而是对于 n 个事件判断相互独立需要 $C_n^2 + C_n^3 + \cdots + C_n^n = 2^n - n - 1$ 个等式成立。而不是 C_n^2 。两两独立不能保证多个事件相互独立。

独立性与互斥、对立性无关。两者是不同维度的问题。

五大概率公式

- 加法公式
 - $P(A \cup B) = P(A) + P(B) - P(AB)$
- 减法公式
 - $P(A - B) = P(A) - P(AB)$
- 乘法公式
 - $P(AB) = P(A)P(B|A) = P(B)P(A|B)$
 - $P(A_1 A_2 \cdots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \cdots P(A_n|A_1 A_2 \cdots A_{n-1})$
- 全概率公式

- $P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$, 其中 A_i **两两互斥**, 且 $\bigcup_{i=1}^n A_i = \Omega$ (完备事件组)。
- 贝叶斯公式 (条件同样是完备事件组, 但是是求完备事件组当中个事件的概率)

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_{j=1}^n P(A_j)P(B|A_j)}$$

古典模型、几何模型、伯努利模型

- 古典模型: 有限、等可能
- 几何模型: 可能性与几何度量成正比

伯努利模型

- 独立重复试验: 独立、重复若干次、各次实验的同一事件发生概率相同。
- 伯努利实验: 每次试验只有两种的结果的独立重复试验。 A 和 \bar{A}

n 重伯努利试验中, 事件 A 发生 k 次的概率为 (二项概率公式):

$$P_n(k) = C_n^k p^k (1-p)^{n-k}$$

随机变量及其概率分布

随机变量及其分布函数

- 在 Ω 上的 **实值函数** $X = X(\omega)$, 称 X 为 **随机变量**。
- **分布函数**: $F(x) = P(X \leq x)$ 。注意是 \leq 。

离散型随机变量

- 随机变量取值是 **有限多个或者可列无穷多个** 的随机变量。
- 列出所有可能取值的概率, 称为 **概率分布** 或 **分布律**。

连续型随机变量

存在 **非负可积** 函数 $f(x)$, 使得对任意 x 有

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$$

X 为连续型随机变量, $f(x)$ 为 X 的 **概率密度函数**。

常用分布

二项分布

n 重伯努利试验中, 每次试验事件 A 发生的概率为 p , 则发生次数 X 服从二项分布, 记为 $X \sim B(n, p)$ 。

几何分布

$$P(X = k) = (1 - p)^{k-1}p$$

几何分布就是一系列伯努利试验中在 第 k 次 才成功的概率。

超几何分布

$$P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}$$

泊松分布

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad \lambda > 0$$

记 $X \sim P(\lambda)$ 或 $X \sim \pi(\lambda)$ 。

$$\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1。$$

$e^{\lambda x}$ 的麦克劳林展开式，取 $x = 1$ 。

泊松分布是用来近似计算二项分布的，当 n 很大， p 很小时， $np = \lambda$ 时，可以用泊松分布来近似。

下面是连续型随机变量的分布。

均匀分布

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其他} \end{cases}, \quad F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$$

X 在 $[a, b]$ 上服从均匀分布，记为 $X \sim U[a, b]$ 。

指数分布

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}, \quad \lambda > 0, \quad F(x) = \begin{cases} 1 - e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

X 服从参数为 λ 的指数分布，记为 $X \sim E(\lambda)$ 。

无记忆性： $P(X > s + t | X > s) = P(X > t)$ 。

正态分布

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad \text{当 } \mu = 0, \sigma = 1 \text{ 时}, \quad f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

X 服从参数为 μ, σ 的正态分布，记为 $X \sim N(\mu, \sigma^2)$ 。（注意这里参数是方差，而不是标准差）

随机变量 函数的分布

$$Y = g(X)$$

对于 离散型随机变量，其分布律为：

$$P(Y = g(x_i)) = P(X = x_i)$$

若 $g(x_i)$ 有相同值，需要合并。

对于连续型随机变量，设其概率密度函数为 $f_X(x)$ ，两种方法计算 Y 的概率密度函数：

公式法

条件： $y = g(x)$ 单调、可导，且 $g'(x) \neq 0$ 。

取其反函数 $x = h(y)$ ， y 的取值范围为 $[a, b]$ ，则

$$f_Y(y) = \begin{cases} f_X(h(y))|h'(y)|, & a \leq y \leq b \\ 0, & \text{其他} \end{cases}$$

定义法

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = \int_{g(x) \leq y} f_X(x) dx \stackrel{\text{公式法条件}}{=} \int_{-\infty}^{h(y)} f_X(x) dx$$

$$f_Y(y) = F'_Y(y) \stackrel{\text{公式法条件}}{=} f_X(h(y))|h'(y)|$$

多维随机变量及其分布

二维随机变量

分布函数：

$$F(x, y) = P(X \leq x, Y \leq y)$$

边缘分布函数：

$$F_X(x) = P(X \leq x) = P(X \leq x, Y < +\infty) = F(x, +\infty)$$

$$F_Y(y) = P(Y \leq y) = P(X < +\infty, Y \leq y) = F(+\infty, y)$$

条件分布：

在条件 $Y = y$ 下 X 的条件分布函数：

$$\forall \varepsilon > 0, \quad P(y < Y \leq y + \varepsilon) > 0, \\ \lim_{\varepsilon \rightarrow 0^+} \frac{P(X \leq x, y < Y \leq y + \varepsilon)}{P(y < Y \leq y + \varepsilon)} \quad \text{存在}$$

记 $F_{X|Y}(x|y) = P(X \leq x|Y = y)$

连续型随机变量

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

其条件分布：

$$F_{X|Y}(x|y) = \int_{-\infty}^x \frac{f(s, y)}{f_Y(y)} ds, \quad f(x, y) \text{ 在该点连续}$$

其中 $\frac{f(x, y)}{f_Y(y)}$ 为在 $Y = y$ 下 X 的条件密度函数，记 $f_{X|Y}(x|y)$ 。

上面要求连续是因为公式的推导是根据定义展开，然后利用拉格朗日中值定理，极限逼近于 y 的。

$$\lim_{\varepsilon \rightarrow 0^+} \int_y^{y+\varepsilon} f(x, y) dy \stackrel{\text{连续}}{=} \lim_{\varepsilon \rightarrow 0^+} \varepsilon f(x, y)$$

独立性

$$\begin{aligned} P(X \leq x, Y \leq y) &= P(X \leq x)P(Y \leq y), \\ \text{即 } F(x, y) &= F_X(x)F_Y(y), \\ \text{更有 } f(x, y) &= f_X(x)f_Y(y) \end{aligned}$$

对于任意 x, y 都成立。

均匀分布和正态分布

二维均匀分布

$$f(x, y) = \begin{cases} \frac{1}{S}, & (x, y) \in D \\ 0, & \text{其他} \end{cases}$$

其中 S 为 D 的面积。 $P((X, Y) \in D_1) = \frac{D_1 \text{ 的面积}}{S}$ 。

二维正态分布

$$\begin{aligned} f(x, y) &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}, \\ f_X(x) &= \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{(x-\mu_1)^2}{2\sigma_1^2} \right\}, \quad f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{(y-\mu_2)^2}{2\sigma_2^2} \right\} \end{aligned}$$

其中 $-1 < \rho < 1$ 。记为 $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$ 。

性质, 若 $(X, Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$, 则:

- $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ (注意这条反向不一定成立)
- X 与 Y 独立 $\Leftrightarrow \rho = 0$ 。—— $f(x, y) = f_X(x)f_Y(y)$
- $aX + bY \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2 + 2ab\rho\sigma_1\sigma_2)$ ——**正态分布变量函数的分布**
- 可逆变换 $\begin{vmatrix} a & b \\ c & d \end{vmatrix} \begin{vmatrix} X \\ Y \end{vmatrix}$, 即 $(aX + bY, cX + dY)$ 仍然服从二维正态分布。——原本可以构成二维正态分布的变量, 经过线性变换后仍然是二维正态分布。

二维正态分布一定是两个正态分布变量构成的, 但随意两个正态分布变量构成的不一定是二维正态分布。

特别地, $\rho = 0$ 时,

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2} \exp \left\{ -\frac{1}{2} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}$$

两个随机变量函数的分布

离散比较简单, 注意讨论连续的。

$$Z = g(X, Y)$$

X, Y 均为连续型随机变量

$$F_Z(z) = P(Z \leq z) = P(g(X, Y) \leq z) = \iint_{g(x, y) \leq z} f(x, y) dx dy$$

X 为离散型, Y 为连续型

$$F_Z(z) = P(Z \leq z) = P(g(X, Y) \leq z) = \sum_i P(X = x_i) P(g(x_i, Y) \leq z | X = x_i)$$

最大值、最小值

$$Z = \max(X, Y)$$

$$F_Z(z) = P(Z \leq z) = P(\max(X, Y) \leq z) = P(X \leq z, Y \leq z)$$

$$Z = \min(X, Y)$$

$$F_Z(z) = P(Z \leq z) = P(\min(X, Y) \leq z) = 1 - P(X > z, Y > z)$$

随机变量的数字特征

期望和方差

期望

$$P(X = x_k) = p_k, \quad k = 1, 2, \dots,$$

$$\sum_{k=1}^{+\infty} x_k p_k, \quad \text{绝对收敛,}$$

$$E(X) = \sum_{k=1}^{+\infty} x_k p_k$$

$$\int_{-\infty}^{+\infty} x f(x) dx \quad \text{绝对收敛,}$$

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

对任意 X, Y :

$$E(X \pm Y) = E(X) \pm E(Y)$$

$$E(XY) = E(X)E(Y) \Leftrightarrow X, Y \text{ 不相关}$$

方差

$$D(X) = E\{[X - E(X)]^2\} = E(X^2) - [E(X)]^2$$

易知 $E(X^2) \geq [E(X)]^2$

标准差、均方差： $\sigma(x) = \sqrt{D(X)}$ 。

- C 是常数, $D(C) = 0$ 。——反之不一定成立。
- $D(aX + b) = a^2D(x)$
- $D(X \pm Y) = D(X) + D(Y) \pm 2Cov(X, Y)$

常见分布的期望和方差

分布	期望	方差
二项分布 $X \sim B(n, p)$	np	$np(1 - p)$
泊松分布 $X \sim P(\lambda)$	λ	λ
几何分布	$\frac{1}{p}$	$\frac{1-p}{p^2}$
均匀分布 $X \sim U(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布 $X \sim E(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态分布 $X \sim N(\mu, \sigma^2)$	μ	σ^2

矩、协方差和相关系数

矩

- k 阶 **原点矩**: $E(X^k)$
- k 阶 **中心矩**: $E\{[X - E(X)]^k\}$, $k = 2, 3, \dots$
- X 和 Y 的 $k + l$ 阶 **混合矩**: $E(X^kY^l)$
- X 和 Y 的 $k + l$ 阶 **混合中心矩**: $E\{[X - E(X)]^k[Y - E(Y)]^l\}$, $k, l = 1, 2, \dots$

协方差

[终于明白协方差的意义了原创 - CSDN博客](#)

$$Cov(X, Y) = E\{(X - E(X))(Y - E(Y))\}$$

协方差是 X 和 Y 的 $1 + 1$ 阶混合中心矩。

- $Cov(X, Y) = E(XY) - E(X)E(Y)$
- $Cov(X, X) = D(X)$
- $Cov(X, Y) = Cov(Y, X)$
- $Cov(aX, bY) = abCov(X, Y)$
- $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$ ——

相关系数

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)D(Y)}}$$

- 如果 $D(X)D(Y) = 0$, 则 $\rho_{XY} = 0$ 。
- $-1 \leq \rho_{XY} \leq 1$
- $\rho_{XY} = 1$, $Y = aX + b$, $a > 0$ 。——正数就是正相关, 特别等于一时是线性相关。
- $\rho_{XY} = -1$, $Y = aX + b$, $a < 0$ 。
- $\rho_{XY} = 0$, X 和 Y 不相关。

独立一定不相关, 但不相关不一定独立。(但对二维正态随机变量来说两者等价)

大数定律和中心极限定理

切比雪夫不等式

$$\forall \varepsilon > 0, \quad P\{|X - E(X)| \geq \varepsilon\} \leq \frac{D(X)}{\varepsilon^2}$$

含义: 随机变量偏离其均值的程度不会超过方差的多少倍。

随机变量序列 X_1, X_2, \dots , 常数 A , $\forall \varepsilon > 0$, 若

$$\lim_{n \rightarrow \infty} P\{|X_n - A| < \varepsilon\} = 1$$

则称 X_n 依概率收敛于 A , 记为 $X_n \xrightarrow{P} A$ 。

切比雪夫大数定律

随机变量序列 **两两不相关**, 且存在常数 C , 使得 $D(X_n) \leq C$, 则

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right\} = 1$$

含义: 随机变量序列的均值依概率收敛于其数学期望的均值。

伯努利大数定律

$$X_n \sim B(n, p), \forall \varepsilon > 0, \quad \lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} X_n - p\right| < \varepsilon\right\} = 1$$

含义: 大量伯努利试验中, 事件发生的频率趋近于事件发生的概率。

辛钦大数定律

随机变量序列 **独立同分布**, 具有 **相同数学期望** $E(X_i) = \mu$, 则

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right\} = 1$$

含义: 大量独立同分布且期望相同的随机变量序列的均值依概率收敛于其数学期望。

棣莫弗-拉普拉斯中心极限定理

$$X_n \sim B(n, p), \quad \forall x \in \mathbb{R}, \quad \lim_{n \rightarrow \infty} P \left\{ \frac{X_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \Phi(x)$$

含义：大量伯努利试验中，事件发生的频率服从正态分布。

列维-林德伯格中心极限定理

随机变量序列 **独立同分布**，具有 **相同数学期望** $E(X_i) = \mu$ ，**相同方差** $D(X_i) = \sigma^2$ ，则

$$\forall x \in \mathbb{R}, \quad \lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x \right\} = \Phi(x)$$

含义：大量独立同分布且期望方差相同的随机变量序列的和服从正态分布。

数理统计基本概念

- 总体：研究对象的某项数量指标 X 的全体。
- 总体分布： X 的概率分布。
- 总体数字特征： X 的数字特征。
- 个体：总体中的一个元素。

如果随机变量序列 X_1, X_2, \dots, X_n 是从总体中抽取的 n 个 **独立同分布** 的随机变量，则称为一个 **简单随机样本**，简称 **样本**。具体取值称为 **样本值** 或 **观测值**。

统计量

统计量：样本 **不含未知参数** 的函数。统计量也有 **观察值** 一说。

常用统计量

样本均值：

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本方差：

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$n-1$ 是规定，使得样本方差是总体方差无偏估计量。（后面可以知道）

样本的 k 阶原点矩：

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad A_1 = \bar{X}$$

样本的 k 阶中心矩：

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, \quad k = 2, 3, \dots, B_2 = \frac{n-1}{n} S^2$$

作为随机变量的函数，统计量也是随机变量。

统计量与总体数字特征的关系

数学期望

如果总体的数学期望为 $E(X) = \mu$:

$$E(\bar{X}) = E(X) = \mu$$

方差

如果总体的方差为 $D(X) = \sigma^2$:

$$D(\bar{X}) = \frac{D(X)}{n} = \frac{\sigma^2}{n}, \quad E(S^2) = D(X) = \sigma^2$$

k 阶原点矩

如果总体的 k 阶原点矩为 $E(X^k) = \mu_k$:

$$\text{当 } n \rightarrow \infty \text{ 时, } A_k \xrightarrow{P} \mu_k$$

常用统计抽样分布

χ^2 分布 —— 一堆正态分布

随机变量序列 X_1, X_2, \dots, X_n **独立同分布**，且服从标准正态分布 $X_i \sim N(0, 1)$ ，则随机变量

$$\chi^2 = \sum_{i=1}^n X_i^2$$

服从 **自由度** 为 n 的 χ^2 分布，记为 $\chi^2 \sim \chi^2(n)$ 。

- 点 $\chi^2_\alpha(n)$ 使得 $P(\chi^2 > \chi^2_\alpha) = \alpha$ 。称其为上 α 分位数。
- $E(\chi^2) = n$, $D(\chi^2) = 2n$ 。
- $\chi^2(n_1) + \chi^2(n_2) \sim \chi^2(n_1 + n_2)$ —— 前提是两个 χ^2 分布相互独立。

t 分布 —— 一个标准正态分布和一个 χ^2 分布

一个标准正态分布 $X \sim N(0, 1)$ ，一个 χ^2 分布 $Y \sim \chi^2(n)$ ，它们 **相互独立**，则随机变量

$$T = \frac{X}{\sqrt{Y/n}}$$

服从 **自由度** 为 n 的 t 分布，记为 $T \sim t(n)$ 。

- 概率密度函数是 **偶函数**，且当 n 足够大时，近似于 $N(0, 1)$
- 由于它的 **对称性**，会有一个 **双侧** α 分位点 $t_{\alpha/2}(n)$ 。 $P(|T| > t_{\alpha/2}) = \alpha$ 。

F 分布 —— 两个 χ^2 分布

两个相互独立的 χ^2 分布 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, 则随机变量

$$F = \frac{X/n_1}{Y/n_2}$$

服从自由度为 n_1, n_2 的 F 分布, 记为 $F \sim F(n_1, n_2)$ 。

- 显然, $\frac{1}{F} \sim F(n_2, n_1)$ 。可推出

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$$

正态总体的抽样分布

一个正态总体

一个总体 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n 来自总体的一个样本, \bar{X}, S^2 分别是样本均值和样本方差, 则

$$\bar{X} \sim N(\mu, \frac{\sigma^2}{n}), \quad U = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \sim N(0, 1)$$

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad \text{要求 } \bar{X}, S^2 \text{ 相互独立}$$

$$T = \frac{U}{\sqrt{\chi^2/(n-1)}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

$$\chi^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$$

上述几个分布均可根据定义推导。

当总体数字特征是待定参数时: U 含有 μ, σ ; χ^2 仅含有 σ ; T 仅含有 μ 。

两个正态总体

两个总体 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, X_1, X_2, \dots, X_{n_1} 和 Y_1, Y_2, \dots, Y_{n_2} 分别来自两个总体的样本且它们相互独立, $\bar{X}, \bar{Y}, S_1^2, S_2^2$ 分别是两个样本的均值和方差, 则

$$\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \sigma_1^2/n_1 + \sigma_2^2/n_2), \quad U = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \sim N(0, 1)$$

$$\chi^2 = \frac{(n_1-1)S_1^2}{\sigma_1^2} + \frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi^2(n_1 + n_2 - 2)$$

$$T = \frac{U}{\sqrt{\chi^2/(n_1 + n_2 - 2)}} \sim t(n_1 + n_2 - 2)$$

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

上述几个分布均可根据定义推导。

根据上面几个统计量, 可对 $\mu_1 - \mu_2$ 及 σ_1^2/σ_2^2 作估计。

参数估计

点估计

估计量也是统计量，即样本无未知参数的函数映射。

- **点估计**：对于某些关于样本的函数映射 θ （未知参数），可以利用估计量 $\hat{\theta}$ 来估计 θ 。

比如，总体的期望是未知参数，显然它是关于样本的一个函数映射；而样本均值可以作为一个统计量来估计总体的期望，所有样本均值是总体期望的一个估计量。

无偏估计量和更有效的估计量：

- **无偏估计量**： $E(\hat{\theta}) = \theta$
- **更有效的估计量**： $\hat{\theta}_1, \hat{\theta}_2$ 都是 **无偏估计量**，若 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$ ，则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效。

通过计算可以知道，样本的均值 \bar{X} 是总体均值 μ 的无偏估计量，而样本方差 S^2 是总体方差 σ^2 的无偏估计量。（这里从方差无偏估计量的计算可以知道为什么前面样本方差的系数是 $1/(n-1)$ ）

矩估计和最大似然估计比较简单，这里不再赘述。

区间估计

对于给定 α ，如果两个统计量 $\hat{\theta}_1, \hat{\theta}_2$ 满足

$$P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} = 1 - \alpha$$

称随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 为 θ 的 **置信水平** 为 $1 - \alpha$ 的 **置信区间（区间估计）**。

α 其实就是度量置信区间的偏差程度。越小说明置信区间越准确。

利用

$$P\{\theta < \bar{\theta}\} = 1 - \alpha$$

$$P\{\theta > \underline{\theta}\} = 1 - \alpha$$

可以求出参数 θ 的置信水平为 $1 - \alpha$ 的单侧置信 **下限** $\underline{\theta}$ 和 **上限** $\bar{\theta}$ 。

一个正态总体的区间估计

总体 $N \sim (\mu, \sigma^2)$ 。设 X_1, X_2, \dots, X_n 是来自总体的一个样本， \bar{X}, S^2 分别是样本均值和样本方差。求以下情况下待定参数的 置信水平 为 $1 - \alpha$ 的置信区间。

结合 [一个正态总体各种统计量的分布](#)。

待定参数 $\mu; \sigma$ 已知：（利用统计量 U ）

$$\begin{aligned} U &= \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} \sim N(0, 1) \\ \Rightarrow P\{-u_{\alpha/2} < U < u_{\alpha/2}\} &= 1 - \alpha \\ \Rightarrow P\{\bar{X} - u_{\alpha/2}\sqrt{\sigma^2/n} < \mu < \bar{X} + u_{\alpha/2}\sqrt{\sigma^2/n}\} &= 1 - \alpha \end{aligned}$$

可见

$$(\bar{X} - u_{\alpha/2}\sqrt{\sigma^2/n}, \quad \bar{X} + u_{\alpha/2}\sqrt{\sigma^2/n})$$

是 μ 的置信水平为 $1 - \alpha$ 的置信区间。其中 $u_{\alpha/2}$ 是标准正态分布的上 $\alpha/2$ 分位数。

待定参数 μ ; σ 未知: (利用统计量 T)

由于 S^2 是 σ^2 的无偏估计量, 所有考虑用 S 代替 σ , 有:

$$\begin{aligned} T &= \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) \\ \Rightarrow P\{-t_{\alpha/2}(n-1) < T < t_{\alpha/2}(n-1)\} &= 1 - \alpha \\ \Rightarrow P\{\bar{X} - t_{\alpha/2}(n-1)S/\sqrt{n} < \mu < \bar{X} + t_{\alpha/2}(n-1)S/\sqrt{n}\} &= 1 - \alpha \end{aligned}$$

可见置信区间为:

$$(\bar{X} - t_{\alpha/2}(n-1)S/\sqrt{n}, \quad \bar{X} + t_{\alpha/2}(n-1)S/\sqrt{n})$$

其中 $t_{\alpha/2}(n-1)$ 是自由度为 $n-1$ 的 t 分布的上 $\alpha/2$ 分位数。

待定参数 σ^2 ; μ 已知: (利用统计量 χ^2)

$$\begin{aligned} \chi^2 &= \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1) \\ \Rightarrow P\{\chi^2_{1-\alpha/2}(n-1) < \chi^2 < \chi^2_{\alpha/2}(n-1)\} &= 1 - \alpha, \quad \text{当 } \chi^2_{1-\alpha/2}(n-1) < \chi^2_{\alpha/2}(n-1) \\ \Rightarrow P\left\{\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)} < \sigma^2 < \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}\right\} &= 1 - \alpha \end{aligned}$$

可见置信区间为:

$$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \quad \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right)$$

注意这是当 $\chi^2_{1-\alpha/2}(n-1) < \chi^2_{\alpha/2}(n-1)$ 时的情况。

两个正态总体的区间估计

结合 [两个正态总体各种统计量的分布](#)。

求 $\mu_1 - \mu_2$ 的置信区间; σ_1, σ_2 已知

$$\begin{aligned} U &= \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \sim N(0, 1) \\ \Rightarrow P\{-u_{\alpha/2} < U < u_{\alpha/2}\} &= 1 - \alpha \\ \Rightarrow P\{(\bar{X} - \bar{Y}) - u_{\alpha/2}\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2} < \mu_1 - \mu_2 < (\bar{X} - \bar{Y}) + u_{\alpha/2}\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}\} &= 1 - \alpha \end{aligned}$$

可见置信区间为:

$$\left((\bar{X} - \bar{Y}) - u_{\alpha/2}\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}, \quad (\bar{X} - \bar{Y}) + u_{\alpha/2}\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2} \right)$$

求 $\mu_1 - \mu_2$ 的置信区间; σ_1, σ_2 未知但 $\sigma_1^2 = \sigma_2^2$

$$\chi^2 = \frac{(n_1 - 1)S_1^2}{\sigma_1^2} + \frac{(n_2 - 1)S_2^2}{\sigma_2^2} = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_1 + n_2 - 2)$$

$$\Rightarrow T = \frac{U}{\sqrt{\chi^2/(n_1 + n_2 - 2)}} = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\chi^2 \sigma^2 / (n_1 + n_2 - 2)} \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$$

$$\Rightarrow P\{-t_{\alpha/2}(n_1 + n_2 - 2) < T < t_{\alpha/2}(n_1 + n_2 - 2)\} = 1 - \alpha$$

$\chi^2 \sigma^2$ 已经把 σ 消掉了。

可见置信区间为：

太长了背它没意义

求 σ_1^2/σ_2^2 的置信区间； μ_1, μ_2 未知

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

$$\Rightarrow P\{F_{1-\alpha/2}(n_1 - 1, n_2 - 1) < F < F_{\alpha/2}(n_1 - 1, n_2 - 1)\} = 1 - \alpha$$

$$\Rightarrow P\{S_1^2/S_2^2/F_{\alpha/2}(n_1 - 1, n_2 - 1) < \sigma_1^2/\sigma_2^2 < S_1^2/S_2^2/F_{1-\alpha/2}(n_1 - 1, n_2 - 1)\} = 1 - \alpha$$

可见置信区间为：

$$\left(\frac{S_1^2/S_2^2}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2/S_2^2}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right)$$

注意这是当 $F_{1-\alpha/2}(n_1 - 1, n_2 - 1) < F_{\alpha/2}(n_1 - 1, n_2 - 1)$ 时的情况。

假设检验

假设检验和两类错误

- 假设检验**：根据样本，按一定规则判断 **假设** H_0 的真伪。

两类错误

假设检验的两类错误		
真实情况(未知)	所作决策	
	接受 H_0	拒绝 H_0
H_0 为真	正确	犯第一类错误
H_0 不真	犯第二类错误	正确

弃真、纳伪。

显著性检验

- 显著性水平**：允许犯第一类错误（弃真）的概率。记 α 。
- 显著性检验**：控制 α 的统计检验。

正态总体参数的假设检验

同参数区间估计。

常见拒绝域。

正态总体均值方差的显著性检验1

检验参数	情形	假设		检验统计量	H_0 为真时 检验统计量的分布	拒绝域
		H_0	H_1			
μ	σ^2 已知	$\mu = \mu_0$ $\mu \leq \mu_0$ $\mu \geq \mu_0$	$\mu \neq \mu_0$ $\mu > \mu_0$ $\mu < \mu_0$	$U = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$	$N(0,1)$	$ U \geq u_{\frac{\alpha}{2}}$ $U \geq u_\alpha$ $U \leq -u_\alpha$
	σ^2 未知	$\mu = \mu_0$ $\mu \leq \mu_0$ $\mu \geq \mu_0$	$\mu \neq \mu_0$ $\mu > \mu_0$ $\mu < \mu_0$	$T = \frac{\bar{X} - \mu_0}{S / \sqrt{n}}$	$t(n-1)$	$ T \geq t_{\frac{\alpha}{2}}(n-1)$ $T \geq t_\alpha(n-1)$ $T \leq -t_\alpha(n-1)$

正态总体均值方差的显著性检验2

检验参数	情形	假设		检验统计量	H_0 为真时 检验统计量的分布	拒绝域
		H_0	H_1			
σ^2	μ 已知	$\sigma^2 = \sigma_0^2$ $\sigma^2 \leq \sigma_0^2$ $\sigma^2 \geq \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$ $\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$	$\chi^2 = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma_0^2}$	$\chi^2(n)$	$\chi^2 \leq \chi_{1-\frac{\alpha}{2}}^2(n)$ 或 $\chi^2 \geq \chi_{\frac{\alpha}{2}}^2(n)$ $\chi^2 \geq \chi_\alpha^2(n)$ $\chi^2 \leq \chi_{1-\alpha}^2(n)$
	μ 未知	$\sigma^2 = \sigma_0^2$ $\sigma^2 \leq \sigma_0^2$ $\sigma^2 \geq \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$ $\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$	$\chi^2(n-1)$	$\chi^2 \leq \chi_{1-\frac{\alpha}{2}}^2(n-1)$ 或 $\chi^2 \geq \chi_{\frac{\alpha}{2}}^2(n-1)$ $\chi^2 \geq \chi_\alpha^2(n-1)$ $\chi^2 \leq \chi_{1-\alpha}^2(n-1)$
$\mu_1 - \mu_2$	σ_1^2, σ_2^2 已知	$\mu_1 - \mu_2 = \mu_0$ $\mu_1 - \mu_2 \leq \mu_0$ $\mu_1 - \mu_2 \geq \mu_0$	$\mu_1 - \mu_2 \neq \mu_0$ $\mu_1 - \mu_2 > \mu_0$ $\mu_1 - \mu_2 < \mu_0$	$U = \frac{\bar{X} - \bar{Y} - \mu_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	$N(0,1)$	$ U \geq u_{\frac{\alpha}{2}}$ $U \geq u_\alpha$ $U \leq -u_\alpha$
	σ_1^2, σ_2^2 未知, 但 $\sigma_1^2 = \sigma_2^2$	$\mu_1 - \mu_2 = \mu_0$ $\mu_1 - \mu_2 \leq \mu_0$ $\mu_1 - \mu_2 \geq \mu_0$	$\mu_1 - \mu_2 \neq \mu_0$ $\mu_1 - \mu_2 > \mu_0$ $\mu_1 - \mu_2 < \mu_0$	$T = \frac{\bar{X} - \bar{Y} - \mu_0}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$	$t(n_1 + n_2 - 2)$	$ T \geq t_{\frac{\alpha}{2}}(n_1 + n_2 - 2)$ $T \geq t_\alpha(n_1 + n_2 - 2)$ $T \leq -t_\alpha(n_1 + n_2 - 2)$
$\sigma_1^2 = \sigma_2^2$	μ_1, μ_2 已知	$\sigma_1^2 = \sigma_2^2$ $\sigma_1^2 \leq \sigma_2^2$ $\sigma_1^2 \geq \sigma_2^2$	$\sigma_1^2 \neq \sigma_2^2$ $\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 < \sigma_2^2$	$F = \frac{n_2 \sum_{i=1}^{n_1} (X_i - \mu_1)^2}{n_1 \sum_{j=1}^{n_2} (Y_j - \mu_2)^2}$	$F(n_1, n_2)$	$F \leq F_{1-\frac{\alpha}{2}}(n_1, n_2)$ 或 $F \geq F_{\frac{\alpha}{2}}(n_1, n_2)$ $F \geq F_\alpha(n_1, n_2)$ $F \leq F_{1-\alpha}(n_1, n_2)$
	μ_1, μ_2 未知	$\sigma_1^2 = \sigma_2^2$ $\sigma_1^2 \leq \sigma_2^2$ $\sigma_1^2 \geq \sigma_2^2$	$\sigma_1^2 \neq \sigma_2^2$ $\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 < \sigma_2^2$	$F = \frac{S_1^2}{S_2^2}$	$F(n_1 - 1, n_2 - 1)$	$F \leq F_{1-\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)$ 或 $F \geq F_{\frac{\alpha}{2}}(n_1 - 1, n_2 - 1)$ $F \geq F_\alpha(n_1 - 1, n_2 - 1)$ $F \leq F_{1-\alpha}(n_1 - 1, n_2 - 1)$

表中 $S_w = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$.

记不来的，一般方法就是：取好相应的检验统计量；假设是相等就利用 上 $\alpha/2$ 分位数算 **双侧置信区间**，大于小于的就利用 上 α 分位数算 **单侧置信区间**；判断统计量是否位于置信区间内以决定拒绝域。